

Caso práctico: almacén de datos para el análisis del impacto conductual de la COVID-19 sobre la población

Solución PRA3- Explotación de datos

Índice de contenidos

1. Explotación de datos	2
2. Creación del modelo OLAP	3
2.1. Creación del proyecto	3
2.2. Vista del origen de datos	5
2.3. Creación e implementación de los cubos	10
2.4. Jerarquías y dimensiones	19
2.5. Explotación del modelo	29



1. Explotación de datos

Esta actividad consiste en realizar la implementación de cubos multidimensionales para la explotación de la información, que va a servir para el análisis de datos y la posterior toma de decisiones.

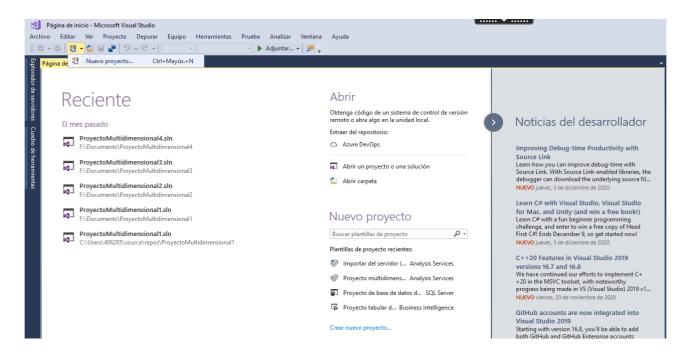
Esta solución de la PRA3 plantea cómo realizar el diseño de un modelo *multidimensional online* analytical processing (OLAP) para el análisis multidimensional de la información disponible en el almacén de datos. Con este fin se va a llevar a cabo lo siguiente:

- 1) Análisis de las provincias con mayor porcentaje de movilidad según los datos móviles.
- 2) Análisis del porcentaje de la población que evitaba las aglomeraciones según la comunidad autónoma.
- 3) Análisis del promedio de sanciones por habitante.
- **4)** Análisis de la evolución de las llamadas de urgencia al 112 en Cataluña por tipología de llamada.
- 5) Análisis de las llamadas de urgencia frente al porcentaje de la población que evitaba las aglomeraciones entre los meses comprendidos entre marzo y junio del 2020 en Cataluña, desglosado por provincia.
- 6) Cálculo del día de la semana con menor número de denuncias.
- 7) Análisis de las diez fechas (*top ten*) con mayor número de llamadas de urgencia al 112 con tipología de tránsito registrada, tanto en época de COVID como antes de ella.

2. Creación del modelo OLAP

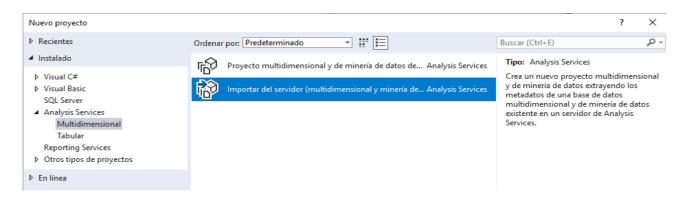
2.1. Creación del proyecto

Iniciaréis Visual Studio 2017 y seleccionaremos «Nuevo proyecto».

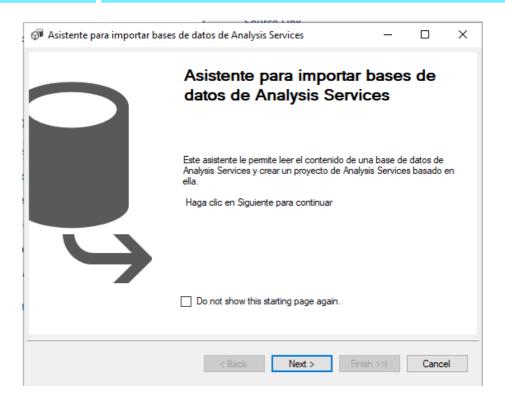


El tipo de proyecto que os interesa es «Proyecto multidimensional y de minería de datos», que permite crear cubos analíticos y realizar proyectos de minería de datos.

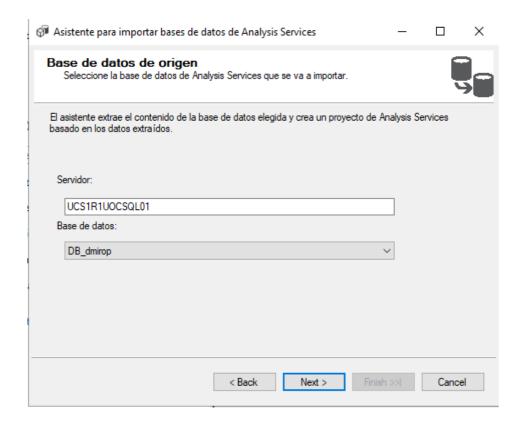
Seleccionaréis la opción «Importar del servidor (multidimensional y minería de datos)».



Le asignaréis un nombre y una ubicación donde guardar el proyecto y seleccionaréis «Aceptar» para iniciar el asistente e importar la base de datos de *Analysis Services*.

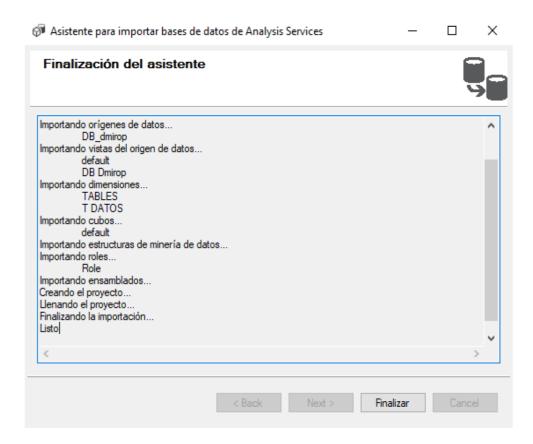


Introduciréis los datos del servidor de Analysis Services (UCS1R1UOCSQL01) y seleccionaréis vuestra base de datos («DB_dmirop», en el ejemplo). Pulsaréis «Next» y se importará la base de datos.



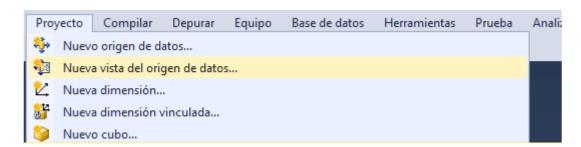


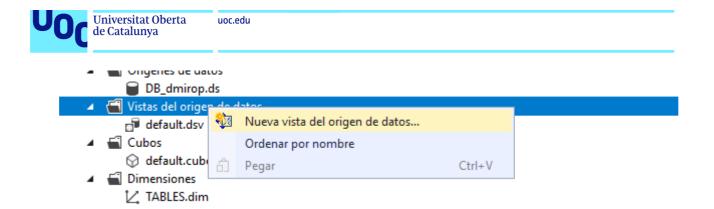
Seleccionaréis «Finalizar». Comprobáis que se ha creado un origen de datos («DB_dmirop») que se corresponde con vuestra base de datos en el servidor. Además, se crea una vista de datos por defecto, con un cubo *default*, una dimensión *tables* y un rol. Estos objetos no deben ser borrados ni utilizados en la realización de la práctica.



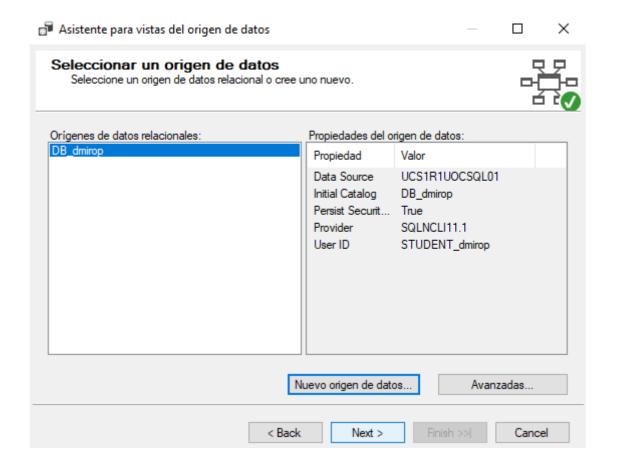
2.2. Vista del origen de datos

A continuación, procederéis a crear las vistas del origen de datos. Para crear cada una de las vistas, elegiréis «Nueva vista del origen de datos» del menú contextual «Vistas del origen de datos» o a en la opción con el mismo nombre del menú «Proyecto».





En el asistente, seleccionaréis «Next».



Vais a crear una vista para cada uno de los cubos. Así definiréis las vistas:

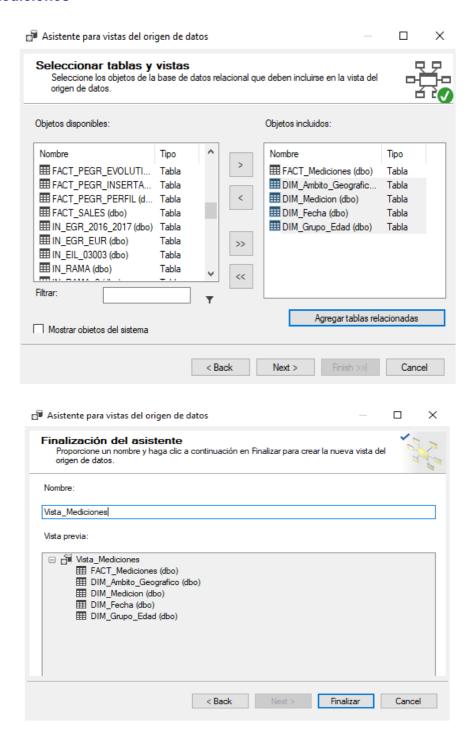
- «Vista_Mediciones»: os dará acceso a las tablas para diseñar el cubo de análisis de mediciones.
- «Vista_Llamadas_112»: os dará acceso a las tablas para diseñar el cubo de análisis de llamadas al 112.

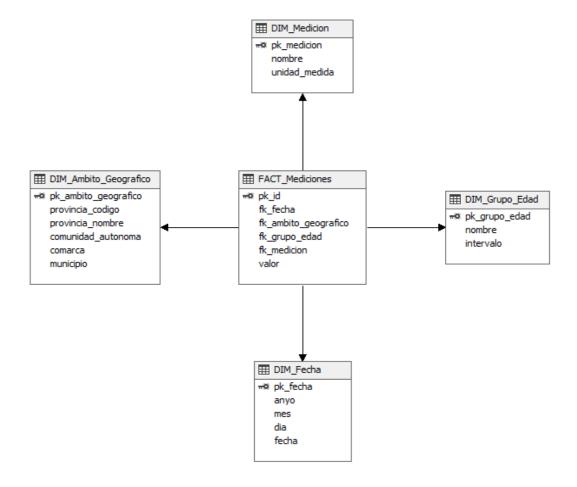
Se seleccionan las tablas necesarias para definir cada una de las vistas de orígenes de datos. Una forma rápida de hacerlo es seleccionar una tabla de hechos y después elegir la opción «add related tables»; esta opción utilizará las claves foráneas para traer las tablas relacionadas.



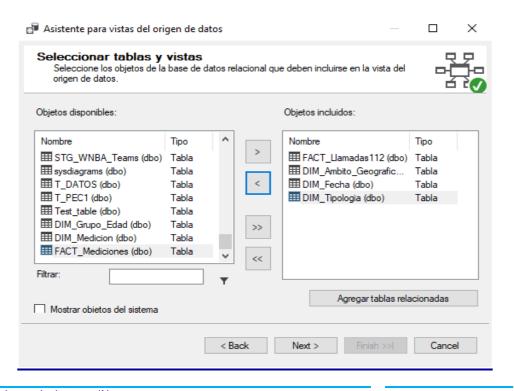
Si se vuelve a seleccionar esta opción, se obtendrán las relacionadas a las ya añadidas. En todo caso, siempre es posible seleccionar las tablas de manera manual.

Vista_Mediciones

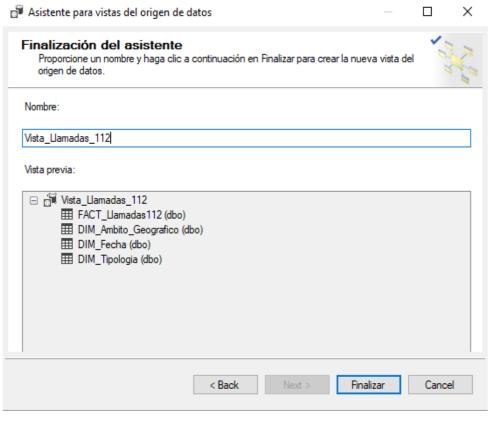


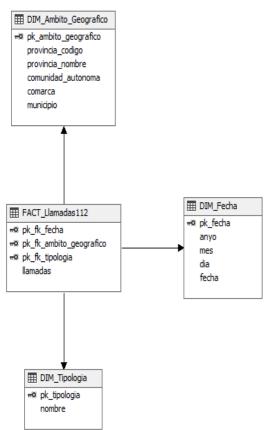


Vista_Llamadas_112







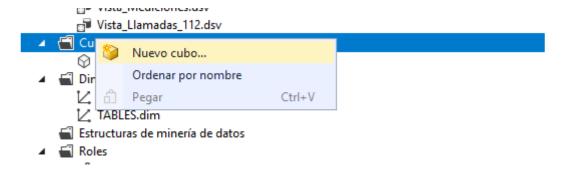




2.3. Creación e implementación de los cubos

Después del paso anterior de creación de las vistas para los orígenes de datos, el siguiente es la creación de los cubos. Este paso os permitirá realizar los análisis OLAP para la explotación de los datos del almacén de datos.

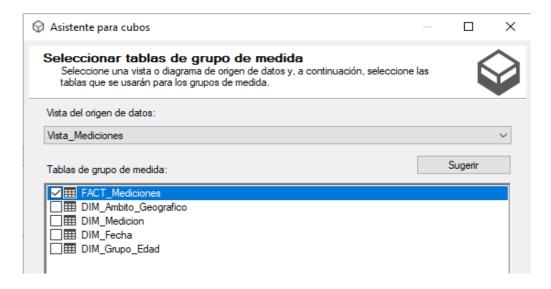
Crearéis cada cubo desde el menú contextual de cubos, seleccionando la opción «Nuevo cubo».



En el asistente, indicaréis que debe utilizar tablas ya existentes y escogeréis cada una de las vistas creadas en el paso anterior para crear el cubo correspondiente.

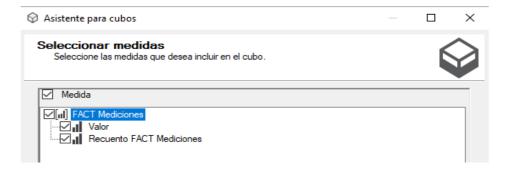
Cubo_Mediciones

Seleccionaréis la vista «Vista_Mediciones» y escogereis la tabla de hechos.



A continuación, seleccionaréis las métricas. Además de las definidas, se añade el recuento para utilizarlo en los análisis y conocer, por ejemplo, el número de métricas realizadas al día.

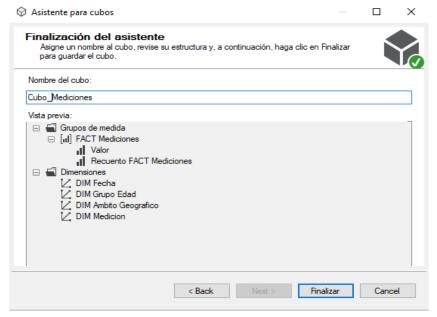




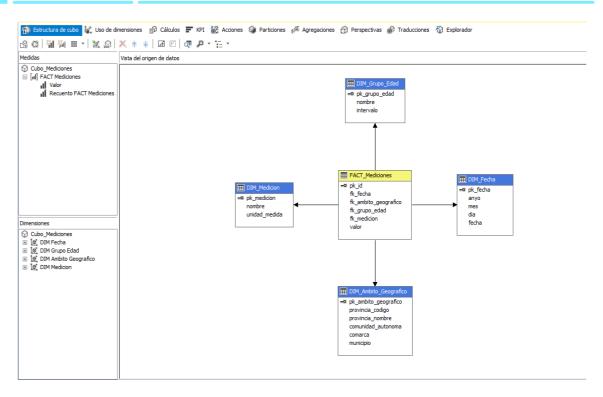
A continuación, seleccionaréis las dimensiones.



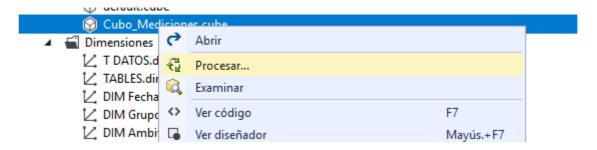
Al finalizar el asistente, visualizaréis la pantalla con el resumen del cubo que queréis crear y le asignaréis un nombre.



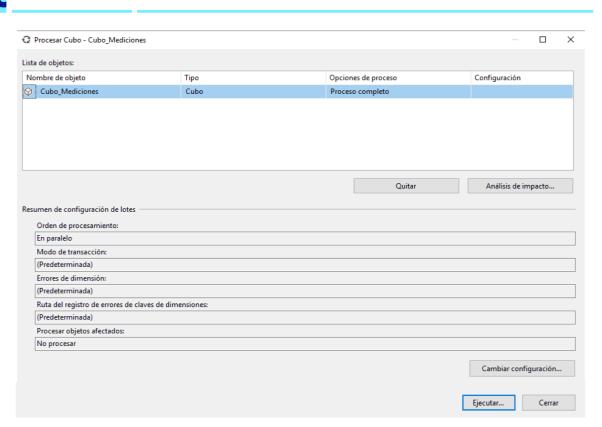
Seleccionaréis «Finalizar» y en la pantalla se mostrará el modelo multidimensional del cubo que se acaba de crear. En la parte izquierda de la pantalla podemos visualizar en forma de árbol las medidas y dimensiones que componen el modelo OLAP del cubo.



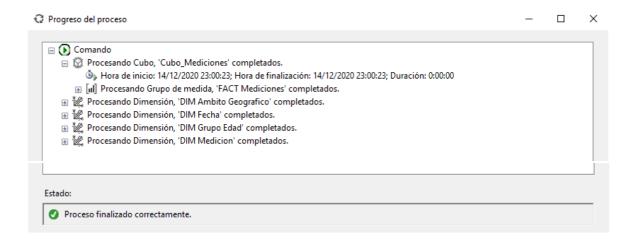
Para poder visualizar los datos del cubo deberéis implementarlo en el servidor de SSAS. Para ello, seleccionaréis la opción «Procesar» en el menú contextual.



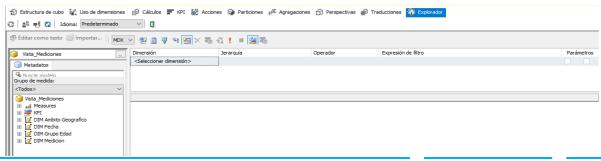
Transcurrido el proceso de implementación, aparecerá la ventana de ejecución del cubo. Seleccionaréis «Ejecutar».



Se mostrará la pantalla confirmando que el cubo se ha procesado correctamente.



Una vez hecho esto, podréis navegar por el cubo a través de la pestaña del «Explorador».

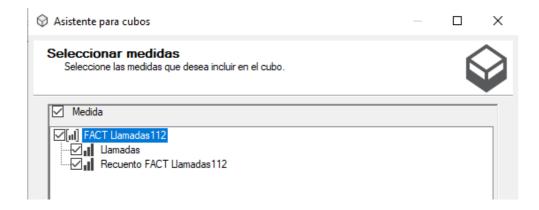


Cubo_Llamadas_112

Seleccionaréis la vista «Vista_Llamadas_112» y pincharéis en la tabla de hechos.



Seleccionaréis las medidas que deseáis implementadas en el cubo.

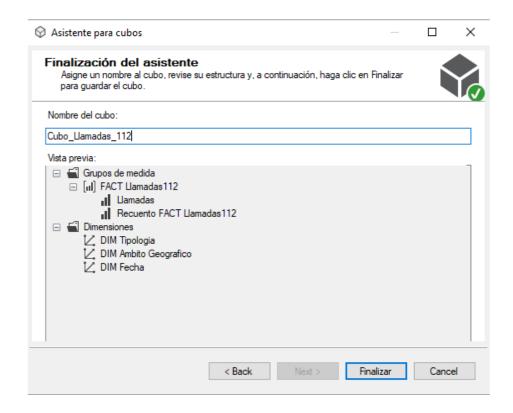


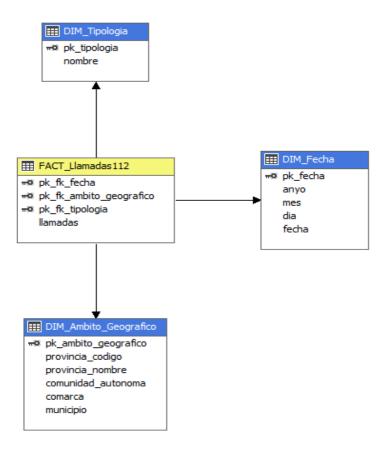
Después escogeréis las dimensiones.





Y, finalmente, le asignaréis un nombre adecuado al cubo y finalizaréis el asistente.



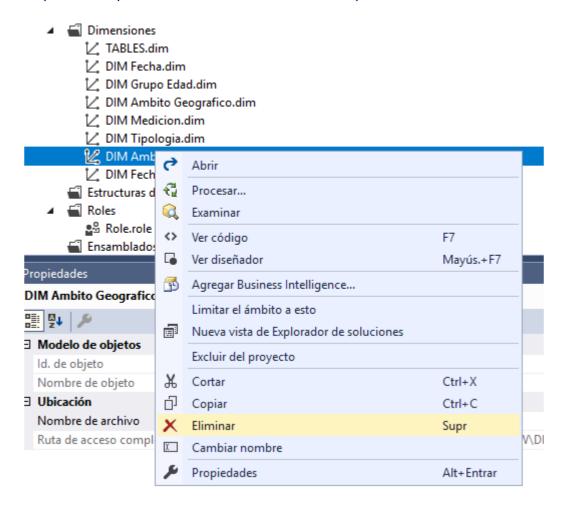




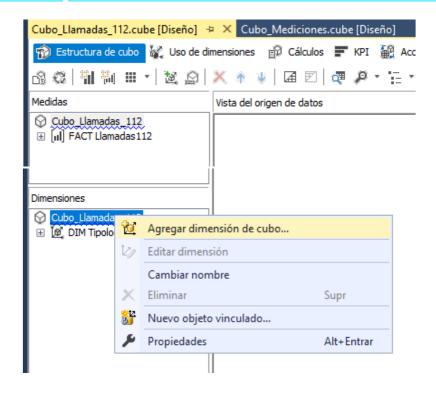
Tras realizar este segundo cubo podréis apreciar cómo algunas dimensiones se han duplicado. Para configurar correctamente las dimensiones conformadas será necesario resolver esta duplicidad.

C DIM Fecha.dim
 DIM Grupo Edad.dim
 DIM Ambito Geografico.dim
 DIM Medicion.dim
 DIM Tipologia.dim
 DIM Ambito Geografico 1.dim
 DIM Fecha 1.dim

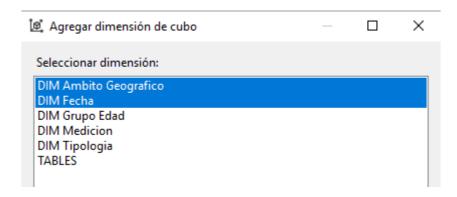
Para ello primero se procede a borrar las dimensiones duplicadas desde el menú contextual.



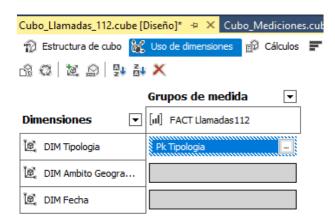
A continuación, deberéis añadir al «Cubo_Mediciones» las dimensiones «**DIM Ambito Geografico**» y «**DIM Fecha**» que ya teníais creadas. Para ello, desde el diseño del cubo, en la pestaña «Estructura de cubo», escogéis la opción «Agregar dimensión al cubo» desde el menú contextual de las dimensiones.



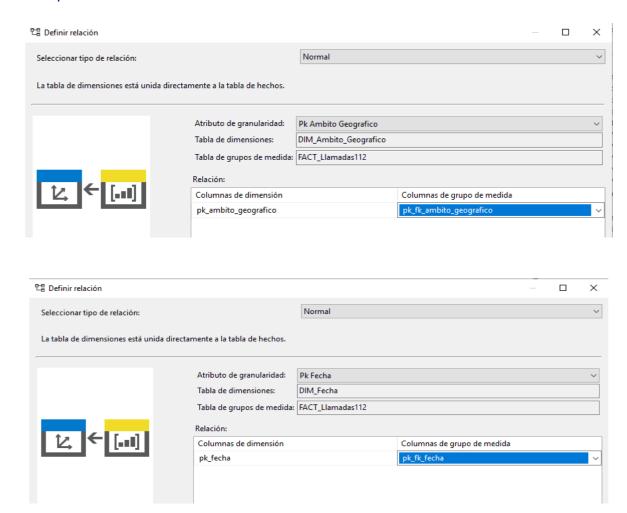
En la ventana que aparece seleccionaréis las dimensiones que se tienen que agregar al cubo para tener el modelo dimensional completo.



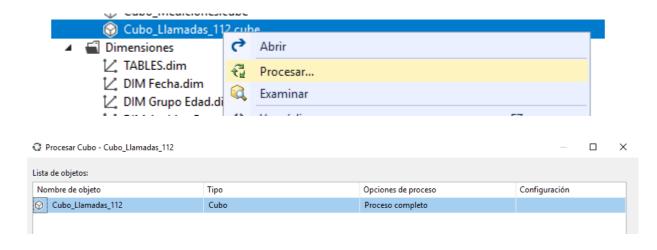
Finalmente, habrá que definir las relaciones entre la tabla de hechos y las nuevas dimensiones. Para ello, deberéis ir a la pestaña «Uso de dimensiones» del diseño del cubo.



Observáis que para las nuevas dimensiones no existe relación alguna. Para definirlas, se hace clic en los puntos suspensivos que aparecen al final del cuadro de texto, donde se especifica el campo que se utilizará para relacionar la tabla de hechos con cada dimensión. Como tipo de relación se escoge «Normal» y se seleccionan los atributos y columnas correspondientes.



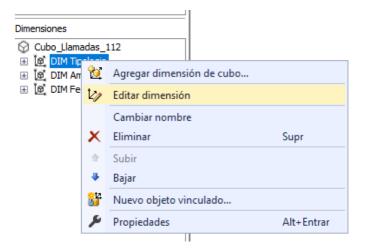
Igual que con el cubo anterior, es necesario procesar el cubo para poder explorarlo.



2.4. Jerarquías y dimensiones

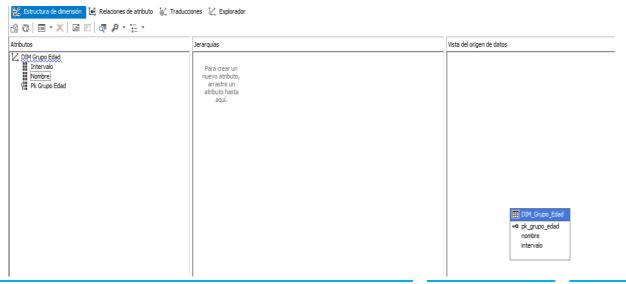
Una vez definidas todas las relaciones del cubo, se trabajará con las dimensiones del proyecto con el objetivo de definir sus atributos y jerarquías. En algunos casos, al tratarse de dimensiones conformadas, es decir, aquellas dimensiones que están compartidas por varias tablas de hechos permitiendo su integración, los cambios realizados tendrán efectos en todos los cubos que las utilicen.

Para definir los atributos y jerarquías de cada dimensión podréis hacer doble clic sobre la dimensión en el apartado «Dimensiones» del «Explorador de soluciones» o elegir la opción «Editar dimensión» desde el menú contextual en la pestaña «Estructura» de cubo.



DIM Grupo Edad

Para editar la dimensión arrastráis los atributos que queráis utilizar desde la zona «Vista del origen de datos» hasta «Atributos».





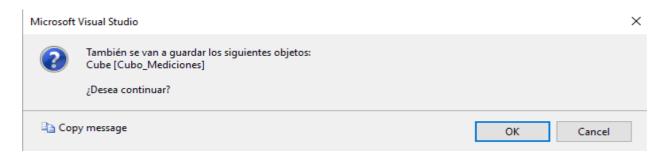
No es necesario seleccionar todos los atributos disponibles, sino solo aquellos que se utilizarán en el análisis de datos. Opcionalmente, es posible renombrar los atributos de la dimensión.

Tras guardar los cambios y volver a procesar la dimensión, podréis ver una advertencia informando de que debemos crear una jerarquía.

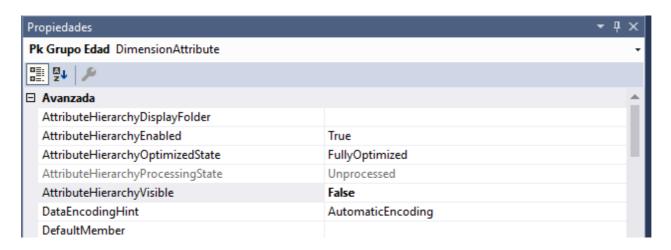


Dimension [DIM Grupo Edad]: Cree jerarquías en dimensiones que no sean de elementos primarios y secundarios.

Esto no es necesario para que el cubo funcione, pero, si no queréis que aparezca la advertencia, podréis seguir la recomendación proporcionada y crear jerarquías sencillas. Sin embargo, en vuestro caso vais a ignorarla, siempre teniendo en cuenta que puede haber algún caso en el que puede ser interesante crearla.



A la hora de analizar los datos los analistas no deberían poder trabajar con valores de tipo clave primaria, dado que estas son de uso interno para la base de datos y, en ocasiones, pueden cambiar entre carga y carga. Además, al tratarse de claves subrogadas, no ofrecen un valor que sea fácil de entender por los analistas. Por todo ello, se oculta seleccionando las propiedades del atributo y cambiando la propiedad a «AttributeHierarchyVisible».





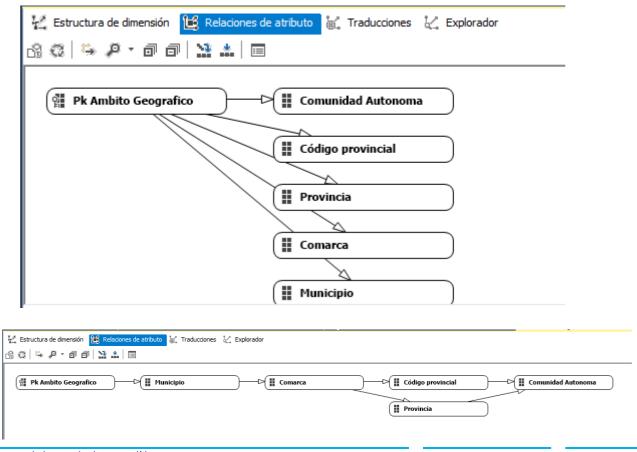
DIM Ambito Geografico

Al igual que en la dimensión anterior, seleccionaréis los atributos que queráis y los renombraremos si es necesario.

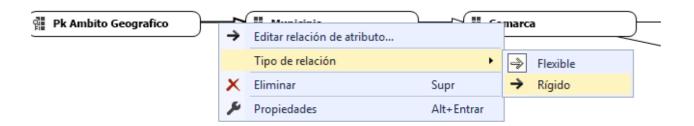
En esta dimensión podréis crear una jerarquía para ir navegando por las diferentes estructuras geográficas. Para ello, seleccionaréis los diferentes atributos que formarán parte de la jerarquía, los iréis agregando a la columna central y asignaréis un nombre a la jerarquía.



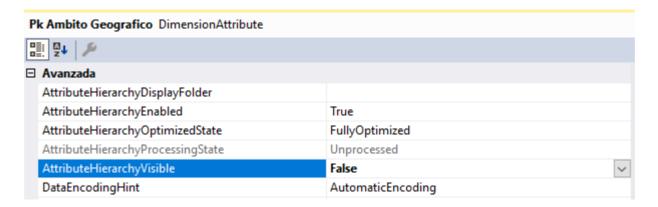
Observaréis advertencias al crearlas avisándoos de que no existen relaciones de atributo. Para subsanarlo, deberéis ir a la pestaña «Relaciones de atributo» y crearlas.



Además, dado que la relación entre estos atributos no va a cambiar (una comarca determinada pertenecerá a una provincia determinada), podréis establecer el tipo de relación como «Rígido». Para ello, abriréis el menú contextual en la relación y cambiaréis el tipo.



Finalmente, ocultaréis el atributo «PK» para facilitar el análisis.



Una vez procesada la dimensión, podréis apreciar una advertencia sobre la necesidad de ocultar los atributos empleados en una jerarquía.



Dimension [DIM Ambito Geografico]: Evite las jerarquías de atributos visibles para los atributos empleados como niveles en las jerarquías definidas por el usuario.

Se pueden ocultar siguiendo el mismo procedimiento que se ha realizado con el atributo «PK» o ignorar, y así posibilitar el escoger esos atributos para los análisis o las jerarquías. En este caso, se decide seguir las recomendaciones.

DIM Medición

Al igual que en otras dimensiones, procederéis a escoger los atributos necesarios y los renombraréis si es preciso. Aparecerá la advertencia de generar una jerarquía y, como en el caso anterior, la ignoraremos.

Como último paso, se procede a ocultar el atributo «PK Medición», al igual que se ha realizado en el anterior caso con el atributo «PK».



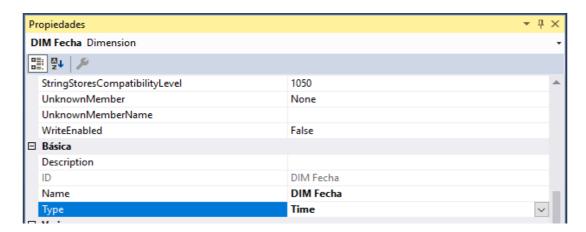
DIM Tipología

Procederéis de la misma manera con esta dimensión, empezando por seleccionar los atributos. Como en los casos anteriores, se ignora la advertencia de creación de una jerarquía y se oculta el atributo «PK Tipología».

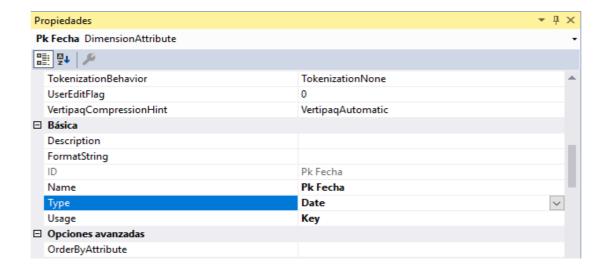
DIM Fecha

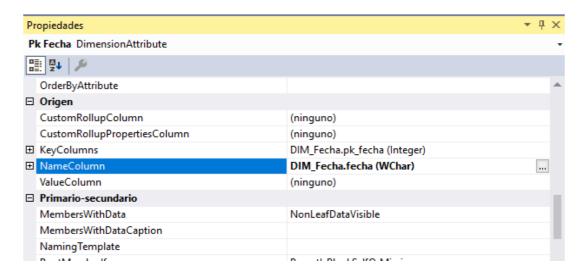
Esta dimensión va a ser la dimensión temporal del modelo. Su estructura se compone de la clave primaria subrogada, año, mes, día y fecha. Como primer paso, escogeréis los atributos pertinentes.

Después, desde la sección «Atributos» de la pestaña de «Estructura de dimensión» visualizaréis las propiedades de la dimensión y cambiaréis el tipo a «Time».

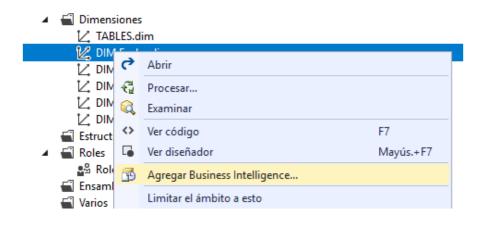


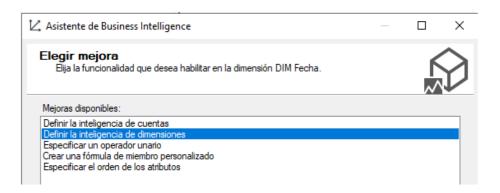
Modificaréis las propiedades de «Pk Fecha» para cambiar el tipo a «date» y «NameColumn» a «Fecha».



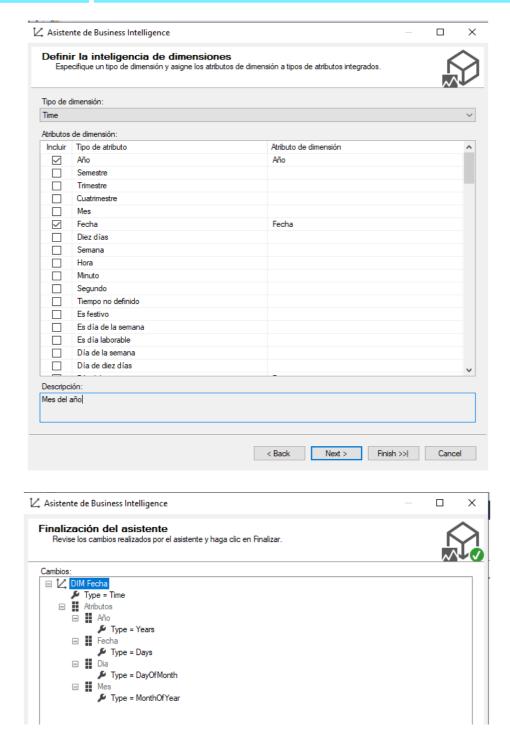


Finalmente, crearéis la jerarquía de días, meses y años, con la opción «Agregar Business Intelligence...».



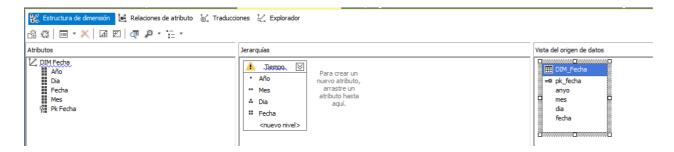




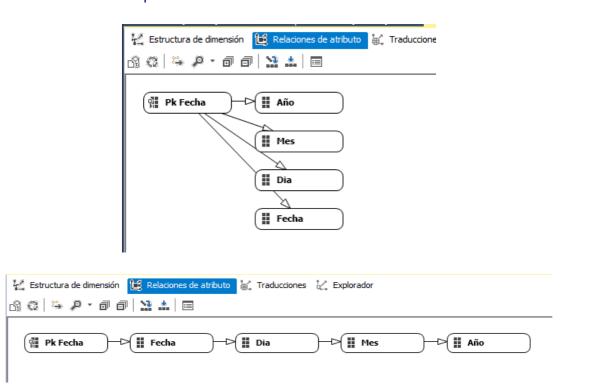


A continuación, se definirá la jerarquía temporal. Podríais usar tanto «Fecha» como «Pk fecha» para el gránulo de la dimensión. Sin embargo, para ser coherentes con el diseño, se decide usar «Fecha» como gránulo.





Sin embargo, aparecerá la advertencia sobre la necesidad de crear relaciones de atributos, como en el caso de la «DIM Ambito Geografico». Por ello, y de la misma manera que antes, se crearán las relaciones pertinentes.

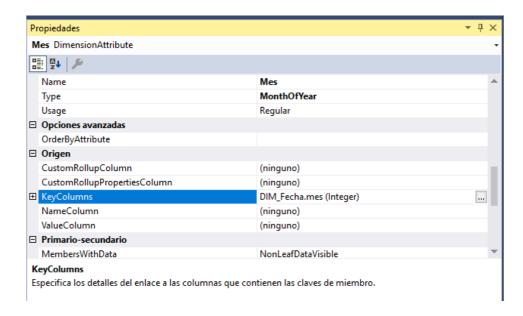


Después se definirán las relaciones como «Rígido».

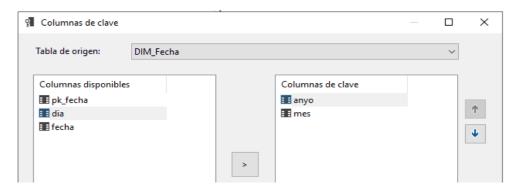




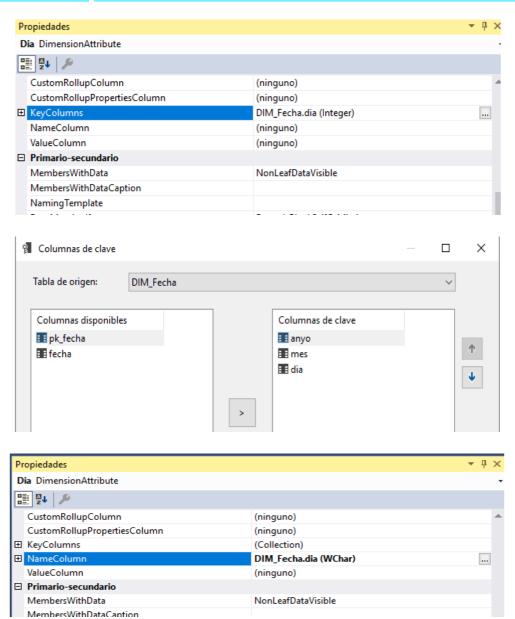
Si vuelven a aparecer errores al implementar, se agregarán los atributos necesarios en la propiedad «KeyColumns» y se le asignará el «NameColumn» correspondiente.











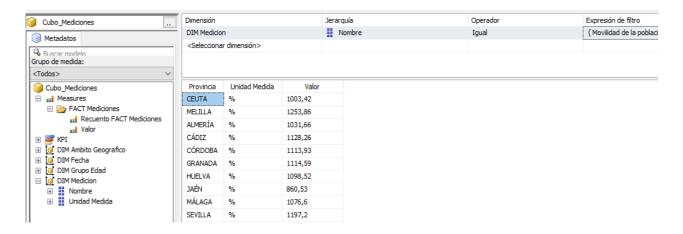
Como con el caso de «DIM Ambito Geografico», os aparecerá la advertencia de evitar las jerarquías de atributos visibles. Por ello, se procede a ocultar los atributos.



2.5. Explotación del modelo

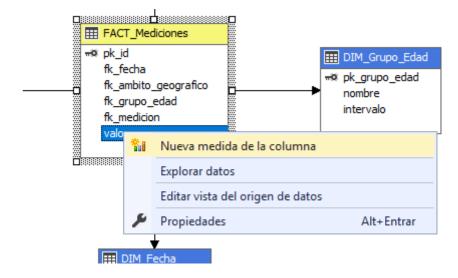
1) Análisis de las provincias con mayor porcentaje de movilidad según datos móviles

Para realizar el análisis del porcentaje de movilidad seleccionaréis, dentro del cubo de «Cubo_Mediciones», la dimensión «Medición» con el atributo «Movilidad de la población durante el estado de alarma». Después, seleccionaréis los diferentes atributos que queráis visualizar en la consulta y los procesaráis.



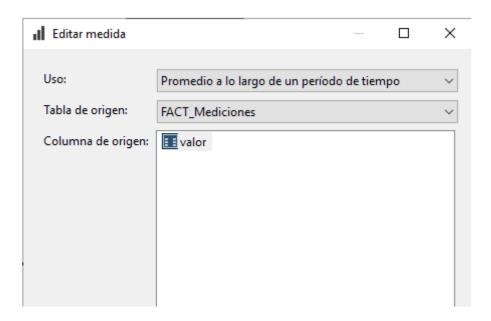
Sin embargo, la explotación ofrece datos incoherentes, dado que los porcentajes no deberían superar el 100 %. Un análisis más detallado os revela que esto es debido a que el valor está agregado como un sumatorio. Así, sería más interesante realizar una media de los porcentajes en función de la provincia. Para ello, agregaréis un nuevo valor agregado.

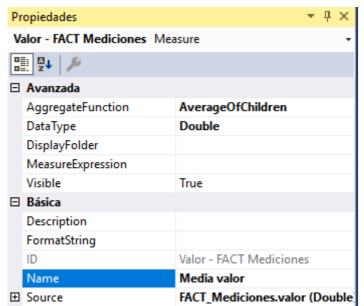
En el apartado de «Estructura de cubo», seleccionaréis la opción «Nueva medida de la columna» del menú contextual sobre el campo «valor» de la tabla de hechos de mediciones.





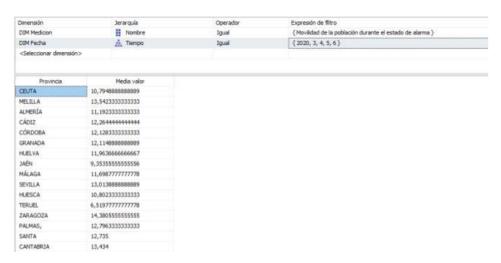
Esto crea una nueva medida disponible. Haciendo doble clic sobre ella, se abre el menú para configurarla. Asignaréis un nuevo tipo de agregación. Para cambiar el nombre, lo editaréis en las propiedades.





Ahora solo tenéis que seleccionar los atributos adecuados para el análisis. Dado que solo os interesa la movilidad durante el estado de alarma, se seleccionan los meses adecuados para el análisis.

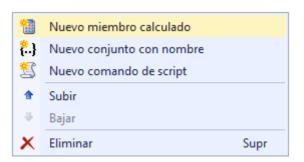


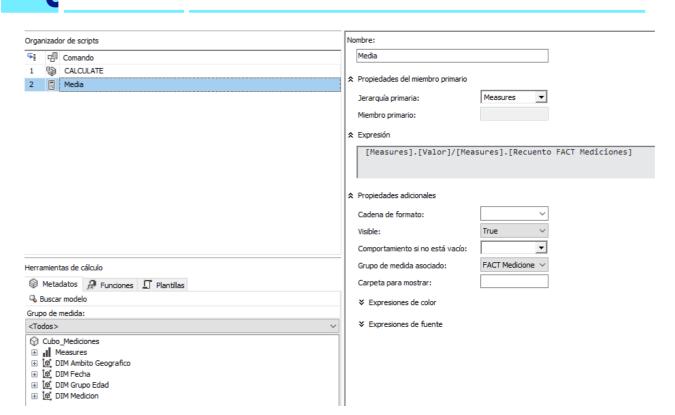


2) Análisis del porcentaje de la población que evitaba las aglomeraciones según la comunidad autónoma

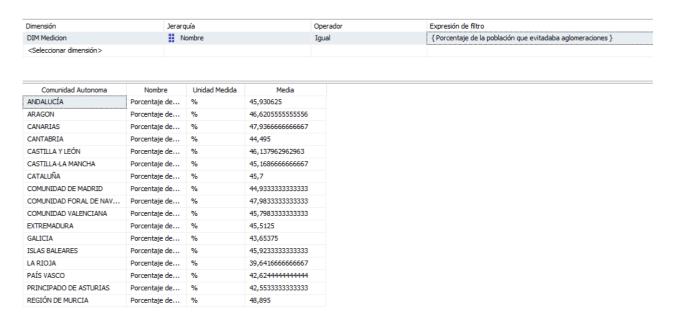
Para realizar este análisis hay que crear una nueva medida calculada, dado que la medida anterior solo tiene en cuenta la dimensión temporal. Para hacerlo, se usará el apartado «Cálculos».

En el menú contextual seleccionaréis la opción «Nuevo miembro calculado». Le dais el nombre adecuado y generáis la expresión arrastrando los campos que os interesen del menú de la izquierda. Además, seleccionaréis el grupo de medida asociado a este nuevo cálculo y procesaremos el cubo de nuevo.





Ahora, en el apartado «Explorador», seleccionaréis los atributos adecuados para generar un listado de la media del porcentaje de la población que evitaba aglomeraciones agrupados por comunidad autónoma.



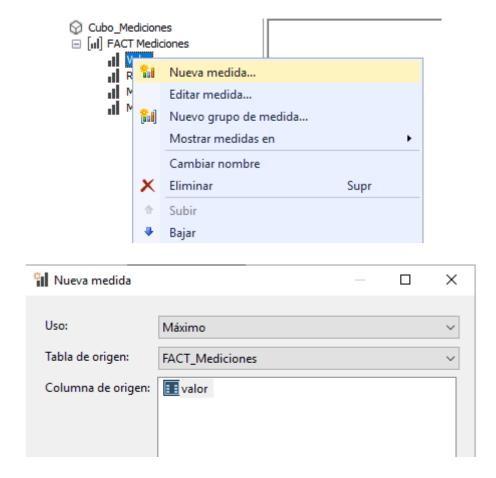
Podéis apreciar que, en general, más de un 40 % de la población de cada comunidad autónoma evitó las aglomeraciones.



3) Análisis del promedio de sanciones por habitante

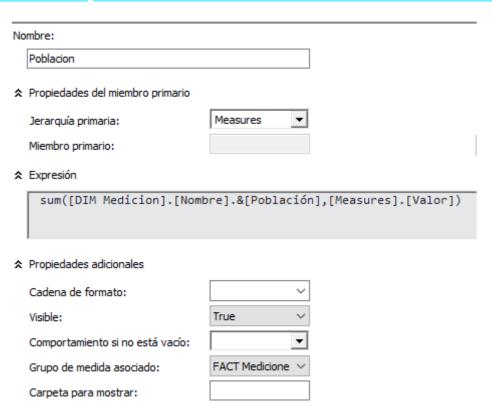
Para este análisis se considerará una sanción tanto una denuncia interpuesta como un vehículo interceptado. Dado que los datos son agregados, tan solo necesitaréis el último valor disponible para estas medidas, por lo que será necesario crear una nueva medida calculada. Además, será necesario crear otro cálculo para poder disponer de la población como un valor.

Para ello, hay que construir una nueva medida a partir de «Valor» para buscar el máximo.

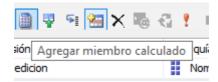


Por otra parte, usando el apartado de cálculos, generaréis un nuevo miembro calculado para calcular la población.

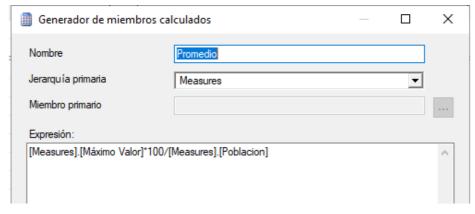




Volvéis a procesar el cubo y pasáis al apartado «Explorador». Ahora, para calcular el promedio no será necesario crear un nuevo miembro calculado, basta con usar la opción de usar la calculadora integrada en el explorador.



Configuraréis el cálculo para hallar el porcentaje de población que ha tenido algún tipo de sanción.



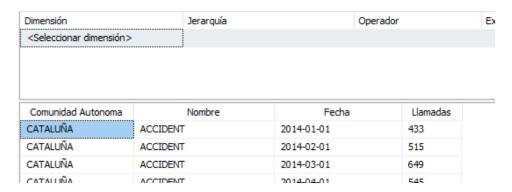


Finalmente, escogeréis los atributos necesarios para realizar la consulta.

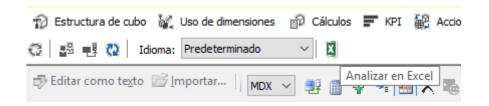


4) Evolutivo de las llamadas de urgencia al 112 en Cataluña por tipología de llamada

Este análisis es relativamente sencillo, dado que solo hay que seleccionar los atributos que se consideren necesarios para obtener los datos.

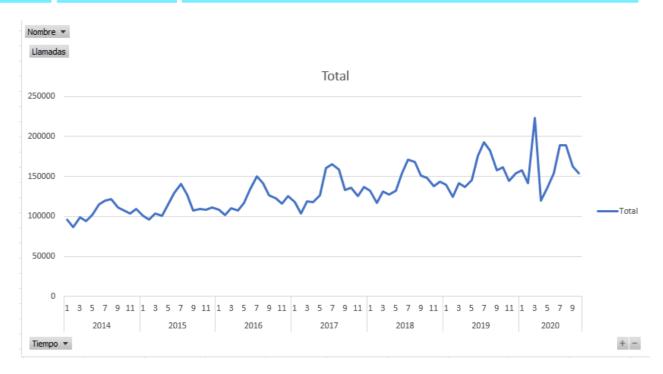


Sin embargo, a la hora de visualizar los datos la tabla no es de gran ayuda para ver las tendencias. Para ello, se utilizará la herramienta «Analizar en Excel» dentro del navegador.

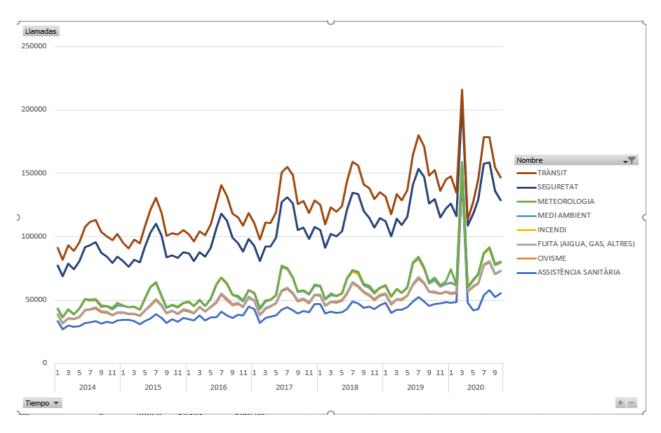


Obtendréis una gráfica dinámica en la que se observa un pico extraño al declararse el estado de alarma.





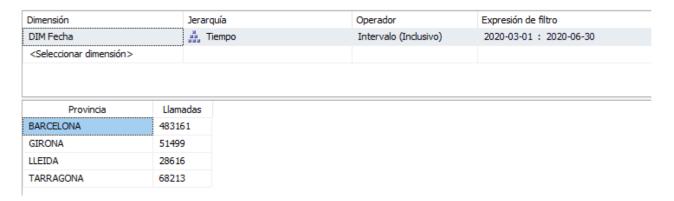
Observando los datos desagregados por tipología, podéis ver que ese pico se reproduce en casi todos los tipos de llamada, por lo que sería necesario comprobar que no se trata de algún error en los datos o de otro tipo de fenómeno.





5) Análisis de las llamadas de urgencia frente al porcentaje de la población que evitaba las aglomeraciones entre los meses comprendidos entre marzo y junio del 2020 en Cataluña, desglosado por provincia

Para realizar la comparación será necesario realizar dos análisis por separado. Primero, se realizará el análisis de las llamadas de urgencia.



Después, el análisis del porcentaje de la población que evitaba las aglomeraciones.

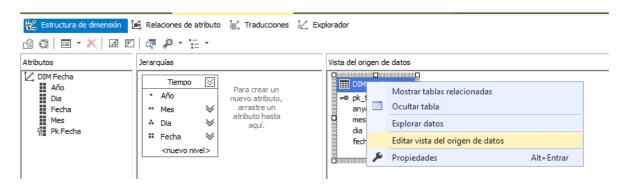


Podéis observar que, a pesar de que en la provincia de Barcelona se hayan realizado más llamadas que en el resto de provincias, eso no se ha visto reflejado en un mayor o menor porcentaje de la población que evitase las aglomeraciones.

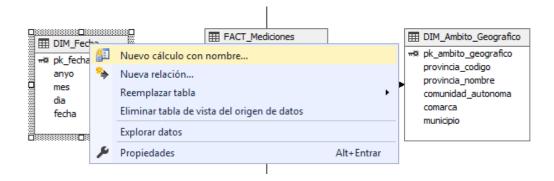
6) Determinar el día de la semana con menor número de denuncias

Para poder realizar esta explotación, es necesario disponer en «DIM Fecha» del día de la semana, lo que no es posible debido al diseño del modelo. Una opción sería modificar la tabla de la dimensión para incluir este nuevo campo, sin embargo, se puede crear un campo calculado en la dimensión. Para ello, abriréis «DIM Fecha» en la pestaña de «Estructura de dimensión» y seleccionaréis la opción «Editar vista del origen de datos» desde el menú contextual.

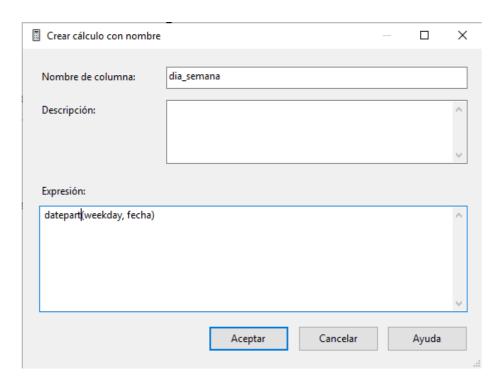




En la vista que aparece, seleccionaréis en el menú contextual en «DIM_Fecha» la opción «Nuevo cálculo con nombre...».

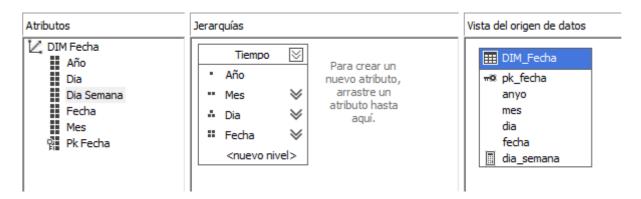


En la ventana que aparece, daréis un nombre al cálculo e introduciréis la fórmula que calculará el día de la semana a partir de la fecha.



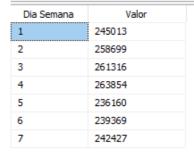


Aceptaréis y, a continuación, en la ventana «Estructura de la dimensión», agregaréis el nuevo atributo a la lista de atributos disponibles.

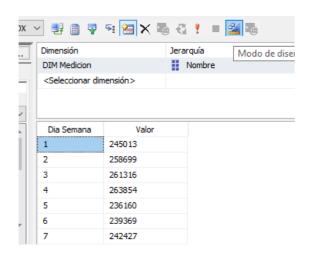


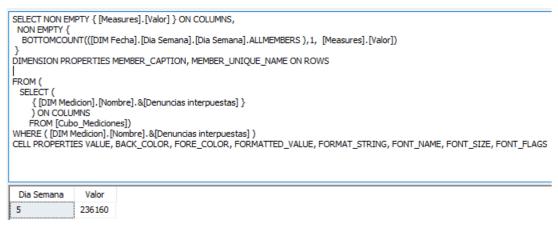
Procederéis a compilar e implementar la solución. Ahora, en el cubo de mediciones, podréis escoger el día de la semana como un atributo a explorar. Configuraréis la consulta y obtendréis el número de denuncias acumuladas por día de la semana.





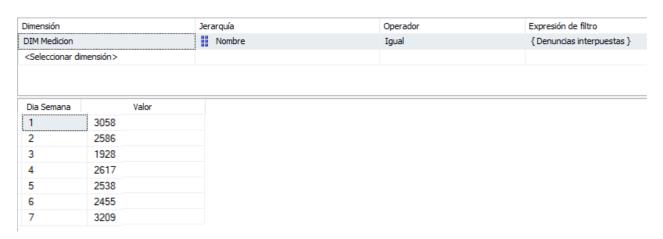
Para poder obtener el día de la semana con menos denuncias acumuladas podréis modificar la consulta en MDX usando la función «BOTTOMCOUNT».





De esta forma se muestra que el día de la semana con menos denuncias es el viernes.

Si seguimos la alternativa propuesta en la PRA2 consistente en cargar los datos de denuncias diarias obtendremos los siguientes resultados:



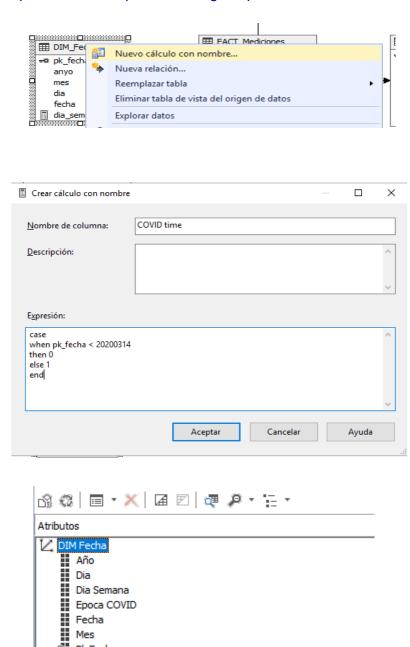
Y usando la función «BOTTOMCOUNT» vemos que el día de la semana con menos denuncias es el miércoles.





7) Análisis de las diez fechas con mayor número de llamadas de urgencia 112 con tipología de tránsito registrada, tanto en época de COVID como antes

Para realizar este análisis vais a generar otro campo y así facilitar la explotación. Consideraréis el 14 de marzo de 2020 como la fecha a partir de la cual se define la «época COVID». Generaréis un campo calculado nuevo en la dimensión temporal que permita distinguir las fechas según esta época. Para ello, procederéis igual que en el caso anterior.



Pk Fecha



Volvéis a procesar la dimensión temporal y el cubo y realizáis una primera explotación de las llamadas antes de la época COVID.

Dimensión	Jerarquía	Operador	Expresión de filtro
DIM Fecha	Epoca COVID	Igual	{0}
DIM Tipologia	Nombre	Igual	{TRÀNSIT}
<seleccionar dimensión=""></seleccionar>			

Fecha	Llamadas
2014-01-01	14036
2014-02-01	12901
2014-03-01	14285
2014-04-01	14318
2014-05-01	14682
201125 21	40070

Realizaréis la modificación en MDX para usar la función «TOPCOUNT».

Año	Mes	Dia	Fecha	Llamadas
2019	7	1	2019-07-01	26694
2018	7	1	2018-07-01	24518
2017	7	1	2017-07-01	24279
2018	10	1	2018-10-01	23640
2019	8	1	2019-08-01	23640
2019	6	1	2019-06-01	23437
2017	6	1	2017-06-01	23095
2019	10	1	2019-10-01	23067
2019	12	1	2019-12-01	22775
2017	8	1	2017-08-01	22674



Para realizar el análisis en «época COVID» no es necesario volver al modo anterior, dado que podréis modificar sin problemas el filtro desde MDX.

```
SELECT NON EMPTY {
NON EMPTY {
TOPCOUNT(([DIM Fecha]. [Tiempo]. [Fecha]. ALLMEMBERS ), 10, [Measures]. [Llamadas])
}
DIMENSION PROPERTIES MEMBER_CAPTION, MEMBER_UNIQUE_NAME ON ROWS
FROM (
SELECT (
{
[DIM Tipologia]. [Nombre]. & [TRÂNSIT] })
ON COLUMNS
FROM ( SELECT ( { [DIM Fecha]. [Epoca COVID]. & [1] }) ON COLUMNS FROM [Cubo_Llamadas_112]))
WHERE ( [DIM Fecha]. [Epoca COVID]. & [1], [DIM Tipologia]. [Nombre]. & [TRÂNSIT] )
CELL PROPERTIES VALUE, BACK_COLOR, FORE_COLOR, FORMATTED_VALUE, FORMAT_STRING, FONT_NAME, FONT_SIZE, FONT_FLAGS
```

Año	Mes	Dia	Fecha	Llamadas
2020	7	1	2020-07-01	20955
2020	8	1	2020-08-01	19881
2020	9	1	2020-09-01	18672
2020	10	1	2020-10-01	17774
2020	6	1	2020-06-01	15749
2020	5	1	2020-05-01	9218
2020	4	1	2020-04-01	4819

Podéis ver que, aunque ha habido menos desplazamientos que en años anteriores, el mes de julio sigue siendo el mes en el que más llamadas sobre tráfico se realizan, a pesar de las restricciones por COVID.